

Universidad de San Andrés
Ingeniería en Inteligencia Artificial
I206 – Inferencia y Estimación

Trabajo Práctico N.º 1

Análisis de Componentes Principales
y Simulación Monte Carlo

Clasificación de radiografías de tórax (PneumoniaMNIST)

Grupo 1

Bautista Alsina	Legajo 370833
Santos Bunge	Legajo 370842
Hans Dietrich	Legajo 370913

Profesores: Copa, Débora; Carducci, Leonardo; García Gulisano Pau

Primavera 2026

Resumen

En este trabajo se estudia la reducción de dimensionalidad de radiografías de tórax mediante Análisis de Componentes Principales (PCA) y su efecto sobre la clasificación de imágenes normales y con neumonía. Se implementa PCA mediante la descomposición en valores singulares y se evalúa una regresión logística al conservar distintas cantidades de componentes. Los resultados obtenidos muestran que representaciones de baja dimensión pueden alcanzar un desempeño comparable al de las imágenes completas. Luego se analiza, mediante simulaciones Monte Carlo, la robustez del sistema frente a rotaciones aleatorias de las imágenes de prueba, y se observa que el desempeño baja a medida que aumenta la probabilidad de rotación. Finalmente, se justifica la estimación de la probabilidad de pérdida mediante la Ley de los Grandes Números y se discuten los alcances y las limitaciones del análisis.

1. Introducción

Una radiografía digital de 128×128 píxeles puede verse como un vector de 16384 números, uno por píxel. Trabajar con vectores tan grandes es costoso y, además, poco eficiente, porque gran parte de esos valores son redundantes: los píxeles vecinos suelen parecerse y todas las radiografías comparten la forma general del tórax. El Análisis de Componentes Principales (PCA) aprovecha esta redundancia. Busca direcciones, formadas por combinaciones de píxeles, ordenadas según cuánta variabilidad de los datos explica cada una, de modo que cada imagen puede describirse con sus primeras K coordenadas. Para medir si esa representación conserva la información importante, usamos un clasificador de regresión logística (LR) que decide si una radiografía corresponde a un paciente sano o con neumonía, y comparamos su *accuracy* (proporción de aciertos) con y sin PCA.

En la segunda parte analizamos qué tan robusto es este sistema si algunas imágenes llegan rotadas 180° . Como no se sabe de antemano cuáles llegarán rotadas, tratamos la situación como un experimento aleatorio y la estudiamos con simulaciones de Monte Carlo, es decir, repitiendo el experimento muchas veces con sorteos independientes y resumiendo los resultados. La Ley de los Grandes Números es la que justifica que esos promedios se acerquen a los valores verdaderos.

Los objetivos del trabajo son: (i) obtener un desempeño de referencia con las imágenes completas; (ii) implementar PCA mediante la descomposición en valores singulares y visualizar los datos en las dos primeras componentes; (iii) analizar el *accuracy* en función de K ; (iv) estimar con Monte Carlo el *accuracy* medio, la probabilidad de superar una pérdida tolerable y la distribución del *accuracy* bajo rotaciones aleatorias; y (v) justificar teóricamente el estimador de probabilidad utilizado.

2. Datos y metodología

Datos. Usamos imágenes de PneumoniaMNIST [2] de 128×128 píxeles en escala de grises, con etiqueta 0 (paciente sano, clase *Normal*) o 1 (*Neumonía*). El conjunto de entrenamiento tiene 2428 imágenes (1214 de cada clase) y el de prueba, 468 (234 de cada clase). Como ambos están balanceados, un clasificador que respondiera al azar obtendría un *accuracy* de aproximadamente 0.5, que tomamos como referencia mínima. Leímos las imágenes en el mismo orden que los archivos de etiquetas, para que cada una quedara asociada a su etiqueta correcta. Luego transformamos cada imagen en un vector fila de 16384 valores y apilamos esos vectores, obteniendo $X_{\text{train}} \in \mathbb{R}^{2428 \times 16384}$ y $X_{\text{test}} \in \mathbb{R}^{468 \times 16384}$.

PCA mediante SVD. Calculamos la imagen media de entrenamiento, μ , y la restamos a cada fila para obtener la matriz centrada $X_c = X_{\text{train}} - \mu$. Luego calculamos su descomposición en valores singulares (SVD) reducida, $X_c = USV^T$ [4]. Las columnas $v_1, v_2, \dots$ de V son las direcciones principales, ordenadas según los valores singulares $s_1 \geq s_2 \geq \dots$, y la fracción de la varianza total

que explica la componente j es $s_j^2 / \sum_i s_i^2$. Para conservar K componentes formamos la matriz V_K con las primeras K columnas de V y proyectamos cualquier conjunto de imágenes como

$$Z = (X - \mu) V_K,$$

donde cada fila de Z contiene las K coordenadas de una imagen. Las decisiones más importantes fueron:

- **Usar SVD en lugar de la matriz de covarianza.** Las direcciones principales son los autovectores de $C = X_c^T X_c / (n - 1)$, pero C tendría 16384×16384 elementos (unos 2 GB de memoria). Como $C = V S^2 V^T / (n - 1)$, la SVD entrega esos mismos autovectores trabajando directamente con los datos, sin construir C .
- **Calcular una sola SVD para todos los K .** La descomposición ya contiene todas las direcciones ordenadas, así que cambiar K solo implica tomar más o menos columnas de V , sin repetir el cálculo más costoso.
- **Calcular μ y V_K solo con el conjunto de entrenamiento.** El conjunto de prueba representa datos nuevos, por lo que no debe usarse en ninguna parte del entrenamiento, y PCA forma parte de esa etapa. Por eso las imágenes de prueba se centran con la media de entrenamiento y se proyectan con sus direcciones.
- **Usar la misma fórmula para ambos conjuntos.** Para las imágenes de entrenamiento se cumple $(X_{\text{train}} - \mu) V_K = U_K S_K$, pero esta igualdad no sirve para las de prueba, porque U corresponde solo al conjunto de entrenamiento. Por eso usamos siempre $Z = (X - \mu) V_K$, que vale para cualquier imagen.

Clasificador y métrica. Como indica la consigna, usamos la regresión logística de *scikit-learn* solo como herramienta para medir cuánta información conserva cada representación, sin analizar su funcionamiento interno [1]. Mantuvimos su configuración por defecto (regularización L_2 , $C = 1$, tolerancia 10^{-4}) y modificamos únicamente el número máximo de iteraciones, por los motivos que se explican a continuación.

Convergencia del ajuste. Empezamos con el máximo de 2000 iteraciones del ejemplo de la consigna. Con ese valor, 21 de los 300 ajustes del barrido lo agotan sin alcanzar la tolerancia y *scikit-learn* emite la advertencia correspondiente (`ConvergenceWarning`): son los K entre 204 y 229, salvo 205, 206, 212, 226 y 227. Fuimos probando entonces con límites cada vez mayores y la cantidad de ajustes afectados fue bajando, pero siempre quedaron siete sin converger: los K entre 218 y 224 no alcanzan la tolerancia por más que se aumente el límite, incluso con valores mucho mayores que los que usamos. No identificamos la causa de ese comportamiento, y resolverlo implicaría usar otras herramientas, algo que queda fuera del alcance de este trabajo.

Fijamos entonces `max_iter` = 20000 para todo el barrido, con el que solo quedan esos siete casos, y dejamos anotado cuáles son. Para medir su efecto los comparamos con ajustes equivalentes que sí llegan a converger: cuatro dan exactamente el mismo *accuracy* y los otros tres difieren en 2, 2 y 6 imágenes sobre 468 ($K = 221, 222$ y 223), es decir como máximo 0.013 de *accuracy*. El ajuste con las imágenes completas converge en 89 iteraciones y el del Ejercicio 2, con $K = 2$, en 11, de modo que ninguno de los dos depende de este límite y el segundo conserva el valor de 2000 del ejemplo. Además, ningún K de los que reportamos en las tablas, en el máximo del barrido o en las conclusiones (Sección 6) cae entre 218 y 224. La falta de convergencia queda así limitada a un tramo corto de la curva de la Figura 2 y no cambia los resultados del trabajo de forma importante.

Entrenamos con `train` y medimos el *accuracy* sobre las 468 imágenes de test. Cada acierto modifica el *accuracy* en $1/468 \approx 0.002$, de modo que una diferencia de 0.01 equivale a unas 5 imágenes. El barrido de K sobre test es descriptivo, como solicita la consigna: el máximo observado no es una estimación independiente del desempeño de un K seleccionado. Para elegir K para un uso posterior habría que validar dentro del conjunto de entrenamiento y reservar test para la evaluación final.

Organización del código. El código se presenta en un único cuaderno de Jupyter, organizado en dos partes correspondientes a los ejercicios 1 y 2. Se definieron funciones para cargar y vectorizar las imágenes, ajustar PCA, proyectar los datos y entrenar y evaluar el clasificador. En la segunda parte se realiza la simulación Monte Carlo. El cuaderno debe ejecutarse en orden desde el inicio y guarda las figuras que se incluyen en este informe; los valores numéricos que citamos son los que imprime en sus salidas. La descomposición en valores singulares y las operaciones con matrices se resuelven con NumPy.

3. Ejercicio 1: PCA y clasificación

3.1. Clasificador con las imágenes completas

Entrenamos la regresión logística con los 16384 píxeles de cada imagen (valores entre 0 y 255) y obtuvimos un *accuracy* de **0.818** (383 aciertos de 468), que usamos como línea de base. El modelo ajusta un peso por píxel y un intercepto con 2428 imágenes de entrenamiento. Esta alta dimensión motiva estudiar representaciones más pequeñas, pero la relación entre número de parámetros y muestras no demuestra por sí sola la existencia de sobreajuste, especialmente cuando se utiliza regularización.

3.2. Proyección sobre las dos primeras componentes

La Figura 1 muestra las imágenes de prueba proyectadas sobre las dos primeras componentes calculadas con el conjunto de entrenamiento. Sobre la componente 1 (eje horizontal) ambas clases ocupan casi todo el rango, por lo que esta coordenada sola tiene una capacidad de discriminación limitada. Sobre la componente 2 (eje vertical), en cambio, las imágenes normales tienden a tomar valores positivos y las de neumonía, negativos. La separación no es perfecta: cerca de cero se mezclan puntos de ambas clases, por lo que cualquier frontera recta va a cometer errores, lo que es coherente con el *accuracy* de 0.803 obtenido con $K = 2$. Los ejes llegan a valores del orden de los miles porque en este cuaderno usamos los píxeles sin normalizar.

3.3. Accuracy en función de la cantidad de componentes

Para cada K entre 1 y 300 proyectamos ambos conjuntos, entrenamos una regresión logística nueva (la cantidad de entradas cambia con K) y medimos su *accuracy*. Elegimos este rango porque muestra tanto el comportamiento con muy pocas componentes como la tendencia para valores grandes de K . Los resultados se presentan en la Figura 2 y en la Tabla 1.




Figura 1: Conjunto de prueba proyectado sobre las dos primeras componentes principales (azul: Normal; rojo: Neumonía).




Figura 2: Accuracy de PCA+LR en función de K y accuracy con la imagen completa (línea punteada).

Tabla 1: Varianza explicada acumulada y *accuracy* sobre el conjunto de prueba para algunos valores de K . Sin PCA, el *accuracy* es 0.818.

K	1	2	3	5	10	20	50	100	200	300
Varianza acumulada	28.3 %	38.4 %	44.7 %	54.0 %	66.0 %	75.5 %	83.9 %	88.7 %	93.1 %	95.2 %
<i>Accuracy</i>	0.596	0.803	0.829	0.857	0.808	0.825	0.829	0.831	0.812	0.784

Con $K = 1$ el *accuracy* es 0.596: esta componente discrimina menos que el par formado por las dos primeras. Con $K = 2$ sube a 0.803 y con $K = 3$ supera la línea de base: 0.829 frente a 0.818. El máximo observado entre 1 y 300 componentes corresponde a $K = 5$ y es 0.857 (401 aciertos). Así, en este conjunto de prueba unas pocas coordenadas permiten obtener un desempeño superior al de la representación completa. La curva no es monótona: para valores intermedios oscila alrededor de la referencia y luego desciende, hasta 0.784 con $K = 300$. Estas variaciones describen los ajustes evaluados y no prueban que las componentes de baja varianza sean ruido ni que la caída se deba exclusivamente al sobreajuste. Además, en el tramo $218 \leq K \leq 224$ se mezclan con el efecto de los siete ajustes que no llegan a converger, por lo que ese tramo de la curva debe leerse con esa aclaración.

La mejora con pocas componentes coincide con la idea de que la reducción de dimensión limita el ajuste de variaciones poco útiles para esta clasificación, aunque para comprobarlo harían falta más evaluaciones.

3.4. Análisis complementario: interpretación de las componentes

Para entender *por qué* alcanzan pocas componentes, hicimos tres análisis adicionales.

Componentes como imágenes. Cada dirección v_j tiene un peso por píxel, así que puede graficarse como una imagen de 128×128 (Figura 3; rojo: pesos positivos, azul: negativos). El signo global de cada componente es arbitrario, por lo que lo que se interpreta es el contraste entre zonas. La **PC1** (28.3 % de la varianza) tiene todos sus pesos del mismo signo, así que mide básicamente el brillo total de la imagen: su correlación con el brillo medio es -0.98 , y el signo negativo solo refleja la elección arbitraria del signo. Esta componente tiene una capacidad de separación individual limitada. La **PC2** (10.1 %) presenta signos opuestos en regiones centrales y periféricas del tórax. El patrón visual sugiere que representa contrastes de intensidad entre esas zonas, que coinciden con diferencias observables entre las clases. Sin embargo, no se midió opacidad pulmonar ni se aislaron factores como exposición, tamaño o encuadre; por eso no interpretamos esta componente como una medida clínica específica. Las **PC3 a PC6** muestran otros contrastes espaciales y menor separación individual. Esto no impide que aporten información cuando se combinan con otras coordenadas.




Figura 3: Imagen media de entrenamiento y primeras seis componentes principales vistas como imágenes.

Varianza explicada. La Figura 4 superpone el *accuracy* con la varianza acumulada. Un criterio habitual es elegir K de modo de conservar el 90 % de la varianza. Aquí eso requeriría 121 componentes, mientras que la línea de base se alcanza con $K = 3$, que conserva solo el 44.7 % de la varianza. La varianza conservada y la capacidad de clasificación miden aspectos diferentes.




Figura 4: *Accuracy* (eje izquierdo) y varianza explicada acumulada (eje derecho) en función de K .

Tabla 2: Varianza, cociente de Fisher F y *accuracy* usando una sola coordenada.

Comp.	Varianza	F	Acc.
PC1	28.3 %	0.232	0.596
PC2	10.1 %	1.477	0.784
PC3	6.3 %	0.067	0.583
PC4	5.7 %	0.074	0.592
PC5	3.7 %	0.031	0.491
PC6	3.2 %	0.063	0.436

Separación por componente. Para cuantificar cuánto separa cada componente por sí sola, calculamos sobre el conjunto de entrenamiento el cociente de Fisher $F = (m_0 - m_1)^2 / (\sigma_0^2 + \sigma_1^2)$, donde m_c y σ_c^2 son la media y la varianza de la coordenada en la clase c . El numerador mide la distancia entre los centros de las clases y el denominador, su dispersión, de modo que un F mayor indica una mejor separación. También medimos el *accuracy* de una regresión logística entrenada con esa única coordenada. La Tabla 2 indica que PC2 tiene la mayor separación individual entre las seis componentes analizadas: su F es más de seis veces el de PC1 y unas veinte veces el de PC3 a PC6, y alcanza un *accuracy* de 0.784 por sí sola. PC1 también aporta cierta separación, aunque menor. PCA ordena las direcciones por varianza sin utilizar las etiquetas, por lo que la dirección de mayor varianza no tiene por qué ser la más útil para clasificar.

4. Ejercicio 2: robustez frente a rotaciones

4.1. Planteo e implementación

Fijamos $K = 2$ y entrenamos PCA+LR una sola vez con las imágenes de entrenamiento sin modificar. Las rotaciones se aplican solo a las imágenes de prueba durante las simulaciones. Sin rotaciones, el *accuracy* es $A_0 = 0.803$ (376 aciertos), igual que en el Ejercicio 1 con $K = 2$. En cada realización, A_p es el *accuracy* obtenido cuando cada imagen se rota con probabilidad p , y $L(p) = A_0 - A_p$ es la pérdida. Las decisiones de implementación fueron:

- **Normalización.** Dividimos los píxeles por 255, para que queden entre 0 y 1, porque así el ajuste de la regresión logística converge con más facilidad. La escala uniforme conserva las direcciones de PCA y reescala sus coordenadas, pero no garantiza que la regresión logística regularizada produzca las mismas predicciones con C fijo. En esta ejecución, el *accuracy* sin rotaciones coincidió con el del ejercicio 1 para $K = 2$.
- **Rotación y sorteo.** Para rotar una imagen, reacomodamos su vector como matriz de 128×128 , la giramos dos veces 90° y la volvemos a convertir en vector. Esto equivale a invertir el orden de los píxeles, así que la rotación es una operación lineal. Para decidir si rotar cada imagen generamos U uniforme en $(0, 1)$ y la rotamos si $U < p$. Como $\mathbb{P}(U < p) = p$, cada imagen se rota con probabilidad p , de forma independiente de las demás. Usamos una semilla fija para que los resultados sean reproducibles.
- **Predicciones precalculadas.** La regresión logística clasifica cada imagen por separado, y cada imagen solo puede estar derecha o rotada. Por eso calculamos una única vez las predicciones del conjunto de prueba completamente derecho y completamente rotado, y en cada realización elegimos, imagen por imagen, cuál de las dos usar según el sorteo. El resultado es idéntico al de rotar, proyectar y predecir en cada realización, y lo verificamos con los mismos sorteos para

$p = 0.1, 0.5$ y 0.9 . Así evitamos proyectar y clasificar la matriz de prueba en cada una de las 36000 realizaciones (18 valores de p por 2000 simulaciones).

- **Cantidad de simulaciones.** Elegimos $N_{MC} = 2000$ a partir de la desigualdad de Chebyshev (Sección 5). Para cada p fijado, el desvío estándar del estimador de probabilidad es a lo sumo 0.0112 y la probabilidad de equivocarse en 0.05 o más es como máximo 0.05.
- **Valores de p .** Para los incisos (b) y (c) usamos 18 valores, de 0.05 a 0.90 con paso 0.05, para obtener curvas bien definidas. Para (a) usamos 0.1, 0.3, 0.5, 0.7 y 0.9, además de $p = 0$ como referencia. En (d) mostramos los histogramas de esos mismos cinco valores, que reutilizan las simulaciones de (b) y (c).

4.2. Proyección de las imágenes rotadas (inciso a)

La Figura 5 muestra una realización para cada p , con círculos para las imágenes sin rotar y cruces para las rotadas. La cantidad de rotadas (58, 141, 234, 328 y 431) es cercana al valor esperado $468p$. Lo más llamativo es que las imágenes rotadas de *ambas* clases se agrupan en una franja angosta y diagonal en la parte inferior del gráfico, justo en la zona donde estaban las imágenes con neumonía. A medida que p crece, esa franja concentra más puntos, y con $p = 0.9$ casi desaparecen los círculos azules de la parte superior.




Figura 5: Una realización de las rotaciones para cada p , proyectada sobre las dos primeras componentes. Círculos: imágenes sin rotar; cruces: imágenes rotadas.

Si $R(x)$ es la imagen x rotada, por linealidad se cumple $R(x) - \mu = R(x - \mu) + (R(\mu) - \mu)$. El segundo término es común a todas las imágenes y su proyección vale $(-1.7, -3.9)$ en las coordenadas normalizadas. El primero depende de cada imagen y se proyecta sobre direcciones aprendidas con radiografías sin rotar. En la ejecución observamos que el desvío de PC2 pasa de 5.6 a 2.8 y que las medias de las dos clases rotadas quedan cerca de -4.2 : disminuye la separación de sus centros sobre ese eje. PC1, asociada al brillo global, se conserva en mayor medida (la correlación entre sus coordenadas antes y después de rotar es 0.99). Esta descomposición ayuda a interpretar la franja observada.

Con todo test rotado, el 97.4 % de las imágenes se clasifica como neumonía, frente al 57.3 % sin rotar. La proporción de aciertos en Neumonía pasa de 0.876 a 0.996 y en Normal, de 0.731 a 0.047. El *accuracy* con todo el conjunto rotado, llamado A_1 , es 0.521, próximo a 0.5. Esto se debe a

que el modelo predice casi siempre la misma clase en un conjunto balanceado; no significa que sus decisiones sean aleatorias.

4.3. Accuracy medio en función de p (inciso b)

Para cada p estimamos $\mathbb{E}[A_p]$ con el promedio de los 2000 *accuracies* simulados,

$$\hat{\mathbb{E}}[A_p] = \frac{1}{N_{MC}} \sum_{i=1}^{N_{MC}} A_{p,i}.$$

La Figura 6 muestra que el *accuracy* medio disminuye de forma lineal, desde 0.789 para $p = 0.05$ hasta 0.550 para $p = 0.9$, sin llegar nunca a 0.5. Esta linealidad tiene una explicación sencilla. Sea $c_i^{\text{der}} = 1$ si la imagen i se clasifica bien cuando está derecha (y 0 si no), y c_i^{rot} lo mismo cuando está rotada. Como la imagen se rota con probabilidad p , la probabilidad de acertarla es $(1-p)c_i^{\text{der}} + p c_i^{\text{rot}}$. Promediando sobre las 468 imágenes, por linealidad de la esperanza se obtiene

$$\mathbb{E}[A_p] = (1-p)A_0 + pA_1 \approx 0.803 - 0.282p.$$

La Tabla 3 compara las estimaciones de Monte Carlo con esta recta. Las diferencias son menores que 0.0005 para los 18 valores de p , lo que funciona como una verificación independiente de la simulación.




Figura 6: *Accuracy* medio estimado en función de p , junto con A_0 (discontinua) y el azar (punteada).




Figura 7: Probabilidad estimada de que la pérdida supere $\delta = 0.1$, en función de p .

Tabla 3: Resultados de Monte Carlo ($N_{MC} = 2000$) para algunos valores de p : *accuracy* medio estimado, valor de la recta $(1-p)A_0 + pA_1$, desvío estándar de A_p y probabilidad estimada de que la pérdida supere 0.1.

p	0.10	0.20	0.25	0.30	0.35	0.40	0.45	0.50	0.70	0.90
$\hat{\mathbb{E}}[A_p]$	0.7755	0.7466	0.7330	0.7188	0.7045	0.6904	0.6763	0.6621	0.6057	0.5496
$(1-p)A_0 + pA_1$	0.7752	0.7470	0.7329	0.7188	0.7047	0.6906	0.6765	0.6624	0.6060	0.5496
Desvío de A_p	0.0088	0.0118	0.0129	0.0133	0.0144	0.0145	0.0145	0.0150	0.0134	0.0088
$\hat{\mathbb{P}}_p(L(p) > 0.1)$	0.0000	0.0000	0.0140	0.1335	0.4985	0.8340	0.9715	0.9985	1.0000	1.0000

4.4. Probabilidad de que la pérdida supere la tolerancia (inciso c)

Estimamos $\mathbb{P}_p(L(p) > \delta)$, con $\delta = 0.1$, como la proporción de simulaciones en las que la pérdida superó la tolerancia:

$$\hat{\mathbb{P}}_p(L(p) > \delta) = \frac{1}{N_{MC}} \sum_{i=1}^{N_{MC}} \mathbb{1}\{L_i(p) > \delta\}.$$

La condición $L(p) > 0.1$ equivale a obtener como máximo 329 aciertos: al menos 47 menos que sin rotaciones. La tolerancia de 0.1 corresponde a diez puntos porcentuales de *accuracy*. En los valores de la grilla con $p \leq 0.20$ ninguna de las 2000 simulaciones superó esa tolerancia, pero una frecuencia cero no implica que el evento sea imposible. Para $p = 0.25$ la frecuencia estimada fue

0.0140; para $p = 0.45$, 0.9715, y desde $p = 0.50$ fue próxima a uno. Por lo tanto, no hay un porcentaje de rotaciones que estos resultados permitan declarar libre de riesgo.

La curva tiene forma de S. La media alcanza el umbral $A_0 - \delta$ cerca de $p^* = \delta/(A_0 - A_1) \approx 0.355$, lo cual sitúa la transición cerca de $p = 0.35$. En ese punto la probabilidad estimada es 0.4985. La probabilidad no tiene por qué ser exactamente 1/2 cuando la media coincide con el umbral, porque el *accuracy* es discreto y su distribución no es exactamente simétrica. La transición es estrecha porque las realizaciones se concentran alrededor de su media: en los casos simulados, el desvío estándar es cercano o inferior a 0.015.

4.5. Distribución del *accuracy* (inciso d)

La Figura 8 muestra los histogramas del *accuracy* para $p = 0.1, 0.3, 0.5, 0.7$ y 0.9 , con 2000 realizaciones por valor. Como el *accuracy* solo toma valores de la forma $k/468$, usamos un intervalo centrado en cada valor posible, con ancho $1/468$. Así evitamos que algunos intervalos agrupen dos valores posibles y otros queden vacíos, lo que generaría huecos artificiales. Las distribuciones tienen forma de campana y están centradas en la media estimada, que se desplaza hacia la izquierda al crecer p . El ancho teórico es máximo en $p = 0.5$ y simétrico alrededor de ese valor; los histogramas presentan fluctuaciones muestrales: el desvío es 0.009, 0.013, 0.015, 0.013 y 0.009 para $p = 0.1, 0.3, 0.5, 0.7$ y 0.9 . Esto se explica con el mismo razonamiento del inciso (b). Solo influyen las 188 imágenes cuya clasificación cambia al rotarlas (160 pasan de acierto a error y 28 de error a acierto), y cada una se rota de forma independiente con probabilidad p , por lo que

$$\text{Var}(A_p) = \frac{188p(1-p)}{468^2},$$

que es máxima en $p = 0.5$ y toma el mismo valor en p y en $1 - p$. Para $p = 0.5$ la fórmula da un desvío de 0.0146, muy cercano al 0.0150 observado. La forma de campana se debe a que A_p es una suma de muchas contribuciones independientes, situación en la que el Teorema Central del Límite indica que la distribución se aproxima a una normal.




Figura 8: Histogramas del *accuracy* para $p = 0.1, 0.3, 0.5, 0.7$ y 0.9 , con 2000 realizaciones por caso. La línea discontinua indica la media estimada.

4.6. Estabilidad de las estimaciones

La Figura 9 muestra, para $p = 0.35$, cómo evolucionan las dos estimaciones al acumular simulaciones. Elegimos este valor porque la probabilidad buscada está cerca de 0.5, que es el caso de mayor varianza de la indicadora y, por lo tanto, el más difícil de estimar. Al principio las estimaciones cambian bruscamente (con una sola simulación, la probabilidad solo puede valer 0 o 1), pero luego se estabilizan: la probabilidad queda cerca de 0.50 desde unas 300 simulaciones, y el *accuracy* medio queda alrededor de 0.7045 desde unas 1000. Este es el comportamiento que predice la Ley de los Grandes Números.




Figura 9: Evolución de las estimaciones para $p = 0.35$ según la cantidad de simulaciones acumuladas. Izquierda: *accuracy* medio. Derecha: probabilidad de que la pérdida supere 0.1.

5. Ejercicio 3: Ley de los Grandes Números

Fijado p , en cada simulación se hace un sorteo nuevo e independiente de las rotaciones, mientras que el modelo, el conjunto de prueba y A_0 no cambian. Por lo tanto, $A_{p,1}, \dots, A_{p,N}$ son variables independientes e idénticamente distribuidas (i.i.d.), con la misma distribución que A_p , y lo mismo vale para las pérdidas $L_i(p) = A_0 - A_{p,i}$. Como es habitual, suponemos que los números pseudoaleatorios de la computadora se comportan como sorteos independientes. Definimos $X_i = \mathbf{1}\{L_i(p) > \delta\}$, que vale 1 si en la simulación i la pérdida supera δ , y 0 si no. Las X_i son i.i.d. y tienen distribución de Bernoulli con parámetro $q = \mathbb{P}_p(L(p) > \delta)$, que es justamente la probabilidad que queremos estimar:

$$\mathbb{E}[X_i] = 1 \cdot \mathbb{P}(L_i(p) > \delta) + 0 \cdot \mathbb{P}(L_i(p) \leq \delta) = q, \quad \text{Var}(X_i) = q(1 - q) \leq \frac{1}{4}.$$

El estimador es el promedio muestral

$$\hat{q}_N = \frac{1}{N} \sum_{i=1}^N X_i = \frac{1}{N} \sum_{i=1}^N \mathbf{1}\{L_i(p) > \delta\},$$

es decir, la proporción de simulaciones en las que ocurrió el evento. Por linealidad de la esperanza y por la independencia de las X_i ,

$$\mathbb{E}[\hat{q}_N] = q, \quad \text{Var}(\hat{q}_N) = \frac{q(1 - q)}{N},$$

así que el estimador es insesgado y su varianza disminuye al aumentar N . La Ley Débil de los Grandes Números [3, 4] asegura que el promedio de variables i.i.d. con media y varianza finitas converge en probabilidad a esa media. En este caso podemos verlo directamente con la desigualdad de Chebyshev: para todo $\varepsilon > 0$,

$$\mathbb{P}(|\hat{q}_N - q| \geq \varepsilon) \leq \frac{\text{Var}(\hat{q}_N)}{\varepsilon^2} = \frac{q(1 - q)}{N\varepsilon^2} \leq \frac{1}{4N\varepsilon^2} \xrightarrow{N \rightarrow \infty} 0.$$

Es decir, con suficientes simulaciones, la probabilidad de que la proporción observada se aleje de la probabilidad verdadera en más de ε es tan pequeña como se quiera. Esto justifica estimar

$\mathbb{P}_p(L(p) > \delta)$ como el promedio de las funciones indicadoras. La Ley Fuerte agrega que $\hat{q}_N$ converge a q con probabilidad 1. La estabilización de la Figura 9 es consistente con ese resultado, pero una trayectoria finita no demuestra convergencia casi segura. Con $N_{MC} = 2000$, la cota da un desvío de como máximo $1/\sqrt{8000} \approx 0.011$ y garantiza que $\mathbb{P}(|\hat{q}_N - q| \geq 0.05) \leq 1/(8000 \cdot 0.05^2) = 0.05$. Esta cota es conservadora porque corresponde al peor caso, $q = 0.5$, y vale para cada p fijado, no como una garantía simultánea para toda la grilla. El mismo argumento vale para el estimador de $\mathbb{E}[A_p]$: los $A_{p,i}$ son i.i.d. y toman valores entre 0 y 1, por lo que su varianza es finita y su promedio converge a $\mathbb{E}[A_p]$. La coincidencia con la fórmula exacta en la Tabla 3 aporta una comprobación numérica del estimador.

6. Conclusiones

En el conjunto de prueba analizado, PCA permitió reducir considerablemente la dimensión manteniendo un desempeño comparable al de las imágenes completas. Con tres componentes se obtuvo 0.829 frente a 0.818 sin PCA, y el máximo del barrido de 1 a 300 componentes fue 0.857 con $K = 5$. Conservar el 90 % de la varianza requirió 121 componentes: maximizar varianza conservada y favorecer la clasificación son criterios diferentes. La comparación es descriptiva; no demuestra un K óptimo para datos nuevos ni una causa única para las variaciones del desempeño.

El sistema con $K = 2$ fue sensible a las rotaciones de 180° : con todas las imágenes rotadas el *accuracy* fue 0.521 y la mayoría de las predicciones fueron de neumonía. Monte Carlo permitió estimar la disminución del *accuracy* medio y la probabilidad de una pérdida superior a diez puntos porcentuales. La coincidencia con las fórmulas de media y varianza respaldó la implementación. La Ley de los Grandes Números justifica la consistencia de los estimadores; una frecuencia observada nula no garantiza que el evento sea imposible.

Las principales dificultades fueron el tamaño de las matrices, la convergencia numérica y el costo de repetir las simulaciones. Las abordamos usando SVD sin construir la covarianza, subiendo el límite de iteraciones del ajuste desde las 2000 del ejemplo de la consigna hasta 20000 y dejando documentados los siete casos (K entre 218 y 224) que no convergen con ningún límite, cuyo efecto es de como máximo 6 imágenes sobre 468, y precalculando las dos predicciones posibles por imagen. También mantuvimos la separación entre entrenamiento y prueba y distinguimos los patrones visuales de las componentes de una interpretación causal. Estas precauciones permiten describir los resultados y sus límites sin darles más alcance que el del experimento realizado.

Referencias

- [1] Mahmood, B. (2016). *How to Predict Yes/No Outcomes Using Logistic Regression*. Medium.
- [2] Yang, J. et al. (2024). *MedMNIST+*: PneumoniaMNIST (128×128).
- [3] Leon-Garcia, A. (2008). *Probability, Statistics, and Random Processes for Electrical Engineering* (tercera edición). Pearson Prentice Hall.
- [4] Material teórico de I206 – Inferencia y Estimación (2026): *Análisis de componentes principales y Convergencia – Monte Carlo*. Universidad de San Andrés.